LPAD Crimes — Relatório Técnico Parcial

Projeto Integrador III — Ciência de Dados e Machine Learning | CEUB

Henrique Valle Chaves (demais integrantes)

Setembro de 2026 — entrega parcial

Sumário

Sumário executivo . . . 2
1. Contextualização e perguntas de pesquisa . . . 2
2. Base de dados . . . 2
3. Achado crítico: quebra estrutural na série temporal . . . 4
4. Qualidade dos dados . . . 5
5. Metodologia dos experimentos de agrupamento . . . 6
6. Resultados dos experimentos e diagnóstico . . . 7
7. Resultados preliminares por métodos alternativos . . . 9
8. Erros identificados e plano de correção . . . 10
9. Limitações . . . 11
10. Próximos passos . . . 12
11. Considerações finais . . . 13
Referências . . . 14
Apêndice A — Ambiente e reprodutibilidade . . . 14
Apêndice B — Decisões de tratamento . . . 14

Sumário executivo

Este relatório documenta o estado atual do projeto LPAD Crimes, que investiga padrões de associação em registros de criminalidade do Departamento de Polícia de Los Angeles.

Até o momento foram concluídas a caracterização da base, a análise de qualidade dos dados e dois experimentos de agrupamento com o algoritmo K-Modes. A análise exploratória identificou uma **quebra estrutural na série histórica em março de 2024**, decorrente de migração do sistema de registro do LAPD, que inviabiliza comparações longitudinais cobrindo o período completo.

Os experimentos de agrupamento **não produziram os perfis pretendidos**. O diagnóstico quantitativo mostrou que as partições geradas refletiam predominantemente as variáveis demográficas da vítima, e não o perfil criminal, e que a curva de custo não apresenta ponto de inflexão — indicando ausência de estrutura de agrupamento natural no espaço de atributos utilizado.

Este relatório apresenta esse diagnóstico de forma explícita, identifica cinco falhas metodológicas nos experimentos realizados e estabelece o plano de correção para a próxima etapa. Em paralelo, resultados preliminares obtidos por métodos alternativos (coeficiente V de Cramér e análise de coocorrência) já respondem parcialmente às perguntas de pesquisa e são apresentados na Seção 7.

---

1. Contextualização e perguntas de pesquisa

1.1 Objeto

O projeto analisa registros de ocorrências criminais da cidade de Los Angeles, Califórnia, disponibilizados pelo Departamento de Polícia local (LAPD) em portal de dados abertos. A escolha se justifica pelo volume (mais de um milhão de registros), pela cobertura temporal contínua e pela natureza predominantemente categórica dos atributos, que impõe restrições metodológicas interessantes do ponto de vista de aprendizado não supervisionado.

1.2 Perguntas de pesquisa

O trabalho está organizado em torno de duas perguntas:

PP1 — Existem tipos de crime que ocorrem associados entre si? Ou seja, quando um boletim registra múltiplas tipificações, quais combinações são recorrentes? A hipótese inicial era de que haveria pares estáveis (por exemplo, arrombamento e furto).

PP2 — Existem associações entre tipo de crime, área geográfica e características demográficas das vítimas? Interessa aqui verificar se determinadas divisões policiais concentram tipos específicos de crime, e se o perfil demográfico das vítimas varia sistematicamente entre tipos de crime ou entre áreas.

1.3 Delimitação

O trabalho é descritivo e exploratório. Não se propõe a prever ocorrências futuras nem a inferir causalidade. Uma ressalva de escopo, tratada em detalhe na Seção 8, é que os dados registram **ocorrências notificadas e registradas pela polícia**, e não criminalidade efetiva.

---

2. Base de dados

2.1 Identificação

Item	Descrição
Fonte	Los Angeles Open Data — `data.lacity.org`
Identificador	`2nrs-mtv8` ("Crime Data from 2020 to Present")
Registros	1.004.894
Colunas	28
Período (`DATE OCC`)	01/01/2020 a 30/12/2024
Volume	~255 MB
Unidade de análise	Boletim de ocorrência

Nota sobre a documentação consultada. O dicionário de dados que a equipe utilizou como referência (`63jg-8b9z`, "Crime Data from 2010 to 2019") corresponde ao dataset irmão, de período anterior. O esquema de colunas e as tabelas de código (Crm Cd, Vict Descent, MO Codes) são compartilhados entre os dois conjuntos, o que torna a consulta válida. Na versão final, a referência bibliográfica deve citar `2nrs-mtv8`, que é o conjunto efetivamente analisado.

2.2 Unidade de análise

Cada linha corresponde a **um boletim de ocorrência**, não a uma vítima nem a uma ofensa individual. A distinção é relevante: um boletim pode registrar até quatro tipificações criminais (`Crm Cd 1` a `Crm Cd 4`), e o dataset traz no máximo um conjunto de atributos de vítima por registro. Contagens de "crimes" derivadas de contagem de linhas são, portanto, contagens de boletins.

2.3 Estrutura das colunas

Grupo	Colunas
Identificação	`DR_NO`
Temporal	`Date Rptd`, `DATE OCC`, `TIME OCC`
Geográfico	`AREA`, `AREA NAME`, `Rpt Dist No`, `LOCATION`, `Cross Street`, `LAT`, `LON`
Tipificação	`Part 1-2`, `Crm Cd`, `Crm Cd Desc`, `Crm Cd 1` a `Crm Cd 4`, `Mocodes`
Vítima	`Vict Age`, `Vict Sex`, `Vict Descent`
Contexto	`Premis Cd`, `Premis Desc`, `Weapon Used Cd`, `Weapon Desc`
Desfecho	`Status`, `Status Desc`

A chave primária `DR_NO` não apresenta duplicatas.

2.4 Caracterização descritiva

Tipificações mais frequentes:

Tipificação	Ocorrências
VEHICLE - STOLEN	115.184
BATTERY - SIMPLE ASSAULT	74.821
BURGLARY FROM VEHICLE	63.515
THEFT OF IDENTITY	62.536
VANDALISM - FELONY	61.086

Tipificação	Ocorrências
BURGLARY	57.871

Distribuição geográfica: as 21 divisões policiais variam de 33.129 ocorrências (Foothill) a 69.668 (Central). Central é seguida por 77th Street (61.756) e Pacific (59.513). Estas são contagens absolutas — na ausência de dados populacionais por divisão, não constituem taxas, e Central em particular é distorcida pela população flutuante da região central da cidade.

Desfecho das ocorrências:

Status	Registros	%
Invest Cont (investigação em curso)	802.772	79,9%
Adult Other	109.799	10,9%
Adult Arrest	87.152	8,7%
Juv Arrest	3.285	0,3%
Juv Other	1.879	0,2%

A taxa agregada de prisão (adulto + juvenil) é de 9,0%.

---

3. Achado crítico: quebra estrutural na série temporal

Este é o achado mais importante da fase exploratória e condiciona todas as análises subsequentes.

3.1 Descrição

A contagem mensal de ocorrências mantém-se estável entre 19.000 e 20.000 de janeiro de 2020 a fevereiro de 2024. A partir de março de 2024, cai abruptamente para a faixa de 8.000, permanecendo nesse patamar até o fim da série.

Registros por ano:

Ano	Registros
2020	199.847
2021	209.876
2022	235.259
2023	232.345
2024	**127.567**

3.2 Interpretação

A queda não representa redução de criminalidade. Em março de 2024 o LAPD implantou novo sistema de gestão de registros, alinhado ao padrão NIBRS (*National Incident-Based Reporting System*). A partir dessa data, apenas ocorrências ainda processadas no sistema legado continuaram alimentando este conjunto de dados; os registros do novo sistema passaram a ser publicados em datasets NIBRS separados, com esquema distinto.

3.3 Evidências de suporte

O efeito não é uniforme entre tipos de crime, o que confirma tratar-se de viés de seleção e não de mudança no fenômeno:

- `VEHICLE - STOLEN` passa de 10,5% para 16,9% do total anual em 2024;
- `ASSAULT WITH DEADLY WEAPON` cai de 5,5% para 2,9%;
- A taxa de prisão cai de 8,8% (2023) para 6,1% (2024), acompanhando a mesma descontinuidade — enquanto a série 2020–2023 apresentava declínio suave e monotônico (10,7% → 9,7% → 8,7% → 8,8%).

3.4 Decisão metodológica

Toda análise longitudinal do projeto será truncada em 29/02/2024. Análises que não dependam de comparação temporal podem usar a série completa, desde que a limitação seja declarada.

A extensão da cobertura para 2024–2025 exigiria incorporar os datasets NIBRS, cuja unidade de análise é a ofensa (não o boletim) e que não trazem localização em nível de quadra. Essa integração fica fora do escopo desta etapa.

---

4. Qualidade dos dados

4.1 Valores ausentes

Coluna	Ausentes	%	Natureza
`Crm Cd 4`	1.004.830	99,99%	Estrutural
`Crm Cd 3`	1.002.580	99,77%	Estrutural
`Crm Cd 2`	935.740	93,12%	Estrutural
`Cross Street`	850.666	84,65%	Estrutural
`Weapon Used Cd / Weapon Desc`	677.678	67,44%	Estrutural
`Mocodes`	151.598	15,09%	Misto
`Vict Sex`	144.631	14,39%	Estrutural
`Vict Descent`	144.643	14,39%	Estrutural
`Premis Desc`	588	0,06%	Aleatório

A maioria dos ausentes é **estrutural**: a ausência carrega significado. `Weapon Desc` é vazio em crimes sem arma (furto, fraude, vandalismo); `Cross Street` só é preenchido quando o local é um cruzamento; `Vict Sex` e `Vict Descent` são vazios quando não há vítima pessoa física identificada. Tratá-los como dados faltantes a serem imputados seria um erro conceitual.

4.2 Valores sentinela

Três colunas usam códigos que aparentam ser valores válidos mas representam ausência ou não-aplicabilidade:

`Vict Age` — 26,8% dos registros têm valor 0, que codifica "não aplicável ou desconhecido", não idade zero. O efeito sobre estatísticas descritivas é substancial: a média bruta é 28,9 anos, contra 39,5 anos considerando apenas idades positivas. Há ainda 137 registros com idade negativa (mínimo −4) e um máximo de 120 anos.

`LAT / LON` — 2.240 registros com coordenada (0, 0), padrão da documentação do LAPD para localização não informada. Sem filtro prévio, produzem um agrupamento espúrio no Golfo da Guiné em qualquer análise espacial.

`Vict Sex` e `Vict Descent` — o código `X` significa "desconhecido" e aparece em 97.753 e 106.661 registros respectivamente. Somados aos nulos, isso significa que cerca de 24% dos registros não têm informação demográfica utilizável. Há ainda resíduos de digitação: 114 registros com `H` em `Vict Sex` e um com `-`.

4.3 Vieses de mensuração

Arredondamento de horário. 39,1% dos valores de `TIME OCC` terminam em `:00`, com pico em 1200 (35.198 registros). O horário é frequentemente estimado pela vítima quando o crime não foi presenciado. Análises horárias de granularidade fina não são confiáveis; recomenda-se agregação em faixas do dia.

Defasagem de notificação. A mediana entre `DATE OCC` e `Date Rptd` é de 1 dia, mas 5,9% dos registros apresentam defasagem superior a 30 dias, com máximo de 1.862 dias. Isso implica censura à direita: os meses mais recentes de qualquer recorte estão subcontados.

Anonimização geográfica. Os endereços em `LOCATION` são truncados na centena da quadra por política de privacidade. O conjunto apresenta apenas 77.869 pares de coordenadas distintos para mais de um milhão de registros — os pontos são centroides de quadra, não localizações exatas. Isso limita a granularidade de qualquer análise de concentração espacial.

Divergência interna. `Crm Cd` difere de `Crm Cd 1` em 1.977 registros. A relação entre os dois campos precisa ser padronizada.

4.4 Campo subutilizado: `Mocodes`

O campo `Mocodes` registra códigos de modus operandi, com múltiplos valores por registro separados por espaço (exemplo: `"0416 0334 2004 1822 1414"`). Há 739 tokens distintos no vocabulário, mas 310.912 combinações distintas de tokens. É o campo com maior densidade de informação comportamental do conjunto, e o tratamento adequado (binarização em indicadores por token) é uma das prioridades da próxima etapa.

---

5. Metodologia dos experimentos de agrupamento

5.1 Justificativa do algoritmo

A quase totalidade dos atributos relevantes é categórica nominal (tipo de crime, área, sexo, ascendência, modus operandi). O K-Means é inaplicável: exige espaço métrico e o cálculo de médias, que não têm significado sobre categorias nominais. A codificação *one-hot* seguida de K-Means introduz distorções conhecidas na estrutura de distâncias.

O **K-Modes** (Huang, 1998) é a adaptação natural: substitui a distância euclidiana pela **dissimilaridade de Hamming** (contagem de atributos discordantes) e o centroide pela **moda** de cada atributo dentro do agrupamento. O custo total é a soma das discordâncias de cada registro em relação à moda de seu agrupamento.

5.2 Precisão conceitual sobre o método

Um esclarecimento necessário, pois a formulação inicial do projeto descrevia o K-Modes como um algoritmo de associação.

O K-Modes é um algoritmo **particional**, não associativo. Ele responde à pergunta "quais *registros* se assemelham entre si?", atribuindo cada observação ao centroide mais próximo. Ele não mede coocorrência entre categorias nem gera regras do tipo "se A então B".

Para PP1 (coocorrência entre tipificações), a família correta é a de **regras de associação** (Apriori, FP-Growth). Para PP2 (associação entre variáveis categóricas), a ferramenta é o **teste qui-quadrado de independência**, acompanhado de uma medida de força de associação como o **V de Cramér**.

Essa correção conceitual é um dos principais aprendizados desta etapa e orienta o redesenho descrito na Seção 9.

5.3 Experimentos realizados

	Experimento 1	Experimento 2
Atributos	`AREA`, `Crm Cd`, `Mocodes`, `Vict Sex`, `Vict Descent`	os 5 anteriores + `Crm Cd 1` a `Crm Cd 4`
k	3 (definido a priori)	7 (via método do cotovelo)
Inicialização	Huang	Huang
Amostra	10.000 registros	10.000 registros
Pré-processamento	`fillna(0)` em `Crm Cd 1-4`; `dropna` em `Mocodes`, `Vict Sex`, `Vict Descent`	idem

5.4 Instrumento de diagnóstico

Para avaliar o que cada partição efetivamente capturou, adotou-se a **Informação Mútua Ajustada (AMI)** entre o rótulo de agrupamento e cada atributo de entrada. A AMI mede quanto do rótulo é explicado por uma variável, corrigida para concordância esperada ao acaso. Valores próximos de zero indicam que o atributo não participou da formação dos agrupamentos.

Esta métrica não constava do plano original e foi incorporada durante a análise crítica dos resultados.

---

6. Resultados dos experimentos e diagnóstico

6.1 Experimento 1 — k = 3

Composição das partições:

Agrupamento	n	Perfil dominante
0	4.773	48,5% W; 60,0% M
1	3.257	89,0% H; 57,9% M
2	1.970	48,0% B; 84,3% F

Diagnóstico por AMI:

Atributo	AMI
`Vict Descent`	0,326
`Vict Sex`	0,134

Atributo	AMI
AREA	0,133
Crm Cd	0,065
Mocodes	0,033

Interpretação. A partição foi determinada essencialmente por ascendência e sexo da vítima. Tipo de crime e modus operandi — as variáveis de interesse do projeto — praticamente não participaram. A distribuição de AREA dentro de cada agrupamento é indistinguível da distribuição global (todas as áreas entre 0,2% e 0,8% em qualquer agrupamento).

O resultado é circular: as variáveis demográficas foram fornecidas como entrada e o algoritmo devolveu grupos demográficos. Isso não responde nem PP1 nem PP2. O que foi obtido equivale a uma tabela de contingência Vict Descent × Vict Sex, produzida por um caminho computacionalmente mais custoso.

6.2 Experimento 2 — k = 7

O segundo experimento incorporou o método do cotovelo para seleção de k (testando k de 1 a 50, com init='Cao' e init='Huang') e ampliou o conjunto de atributos com Crm Cd 1 a Crm Cd 4.

Cardinalidade dos atributos utilizados:

Atributo	Níveis	Moda cobre	AMI (k=7)
Mocodes	5.717	6,3%	0,059
Crm Cd	108	8,8%	0,275
Crm Cd 1	107	8,8%	0,276
AREA	21	13,4%	0,149
Vict Descent	14	37,3%	0,209
Vict Sex	3	49,4%	0,282
Crm Cd 2	45	90,3%	0,007
Crm Cd 3	5	99,6%	0,000
Crm Cd 4	2	100,0%	−0,000

Avanço. A AMI de Crm Cd subiu de 0,065 (k=3) para 0,275. Com maior número de agrupamentos, o tipo de crime passa a participar da partição de forma relevante. Este é um progresso real em relação ao Experimento 1.

Curva de custo. O custo cai de forma contínua e sem inflexão, de 38.487 (k=1) a 20.654 (k=50) — redução de 46% distribuída ao longo de 50 agrupamentos. **Não há cotovelo.** Nenhum valor de k se distingue dos vizinhos por critério de custo.

Este é, em si, um resultado interpretável: a ausência de ponto de inflexão indica que os dados **não apresentam estrutura de agrupamento natural** no espaço de atributos utilizado. A escolha de k=7 não é sustentada pela curva.

Instabilidade numérica. Com init='Huang' e n_init=5, o custo **aumenta** em 15 dos 49 incrementos de k (por exemplo, k=6 apresenta custo superior a k=5; k=11 superior a k=10; k=14 superior a k=13). Em uma solução bem convergida, o custo deve ser não-crescente em k. As subidas indicam convergência para ótimos locais, com número de reinicializações insuficiente.

Agrupamento espúrio. Um dos sete agrupamentos é composto majoritariamente por registros com valor X tanto em Vict Sex quanto em Vict Descent — ou seja, é um agrupamento de

ausência de informação demográfica, não um perfil criminal. Não possui interpretação substantiva e não deve ser reportado como perfil.

---

7. Resultados preliminares por métodos alternativos

Enquanto o redesenho do agrupamento não é concluído, as perguntas de pesquisa já receberam respostas parciais pelas ferramentas metodologicamente adequadas.

7.1 PP1 — Coocorrência entre tipificações

Cruzamento de `Crm Cd 1` × `Crm Cd 2` nos 69.154 boletins com dupla tipificação:

Ocorrências	% dos boletins com 2 tipificações	Par
3.191	4,6%	BRANDISH WEAPON + CRIMINAL THREATS
1.287	1,9%	CRM AGNST CHLD + BATTERY WITH SEXUAL CONT
334	0,5%	RAPE, FORCIBLE + CRM AGNST CHLD
252	0,4%	INTIMATE PARTNER - SIMPLE ASSAULT + BRANDISH
250	0,4%	CRM AGNST CHLD + SEXUAL PENETRATION W/FOR
245	0,4%	THEFT PLAIN - PETTY + INTIMATE PARTNER - SIMI

Leitura preliminar. As coocorrências concentram-se em dois eixos: violência interpessoal com escalada (ameaça acompanhada de exibição de arma) e crimes sexuais contra menores. Nenhum par patrimonial aparece entre os mais frequentes, o que **contraria a hipótese inicial** de que pares como arrombamento e furto seriam recorrentes.

Ressalva: a contagem bruta reflete frequência marginal dos tipos envolvidos. A formalização exige medidas de suporte, confiança e *lift*, a serem calculadas na próxima etapa via FP-Growth.

7.2 PP2 — Associação entre variáveis categóricas

Coeficiente V de Cramér, calculado sobre a base completa (sem filtro de categorias) e com correção de viés:

Par de variáveis	Dimensão	V	n
`Crm Cd Desc` × `Vict Sex`	139 × 5	**0,286**	860.246
`Crm Cd Desc` × `Weapon Desc`	122 × 79	0,202	327.131
`Crm Cd Desc` × `Vict Descent`	139 × 20	0,144	860.246
`Crm Cd Desc` × `Premis Desc`	139 × 306	0,131	859.674
`AREA NAME` × `Vict Descent`	21 × 20	0,125	860.246
`AREA NAME` × `Vict Sex`	21 × 5	0,102	860.246
`Crm Cd Desc` × `AREA NAME`	139 × 21	**0,090**	860.246

Todos os testes qui-quadrado retornaram $p < 0{,}001$. Com amostras desta magnitude, contudo, o p-valor é praticamente não informativo — qualquer desvio mínimo da independência é estatisticamente significante. **A interpretação deve se apoiar no tamanho do efeito (V), não na significância.**

Leitura preliminar. A associação mais forte é entre tipo de crime e sexo da vítima (0,286), o que é consistente com a literatura sobre distribuição por gênero de crimes como violência doméstica e roubo. A associação mais fraca é entre tipo de crime e área geográfica (0,090): **as divisões**

policiais de Los Angeles não se especializam em tipos de crime, o que contraria a intuição de "cada bairro com seu crime característico".

Ressalva metodológica: o V de Cramér é normalizado por `min(r-1, k-1)` e portanto não é diretamente comparável entre tabelas de dimensões muito distintas. A ordenação acima deve ser lida como indicativa. Uma versão robusta da comparação está prevista para a próxima etapa.

---

8. Erros identificados e plano de correção

Esta seção registra explicitamente as falhas detectadas na revisão crítica dos experimentos. Todas serão corrigidas na próxima entrega.

E1 — Amostragem não aleatória

O que ocorreu. A amostra de trabalho foi obtida por `df_cluster[:10000]`, que seleciona as 10.000 primeiras linhas do arquivo, não uma amostra aleatória.

Impacto. As 10.000 primeiras linhas são integralmente de 2020, e a distribuição por divisão policial difere substancialmente da global (as áreas 14 e 18 predominam no recorte; a área 1 predomina no conjunto completo). Os experimentos foram conduzidos sobre um recorte enviesado.

Correção. Substituir por `df.sample(n=50000, random_state=42)`. O algoritmo suporta volumes consideravelmente maiores que 10.000 registros.

E2 — Exclusão desbalanceada de registros

O que ocorreu. A remoção de nulos em `Mocodes`, `Vict Sex` e `Vict Descent` elimina 15,1% dos registros, mas não de forma uniforme entre tipos de crime.

Impacto. `VEHICLE - STOLEN` perde 99,5% dos registros (de 115.184 para 546); `THEFT FROM MOTOR VEHICLE - PETTY` perde 59,0%. Os demais tipos do top 12 perdem menos de 4%. O crime mais frequente do conjunto (11,5% do total) foi efetivamente removido da análise, porque furto de veículo não possui vítima pessoa física com sexo e ascendência registrados.

Correção. Substituir a exclusão por categoria explícita `"NAO_APLICAVEL"`, ou declarar formalmente o escopo como restrito a crimes com vítima pessoa física identificada. A primeira alternativa é preferível.

E3 — Cardinalidade desbalanceada entre atributos

O que ocorreu. `Mocodes` entrou no modelo como cadeia de caracteres única, gerando 5.717 níveis distintos na amostra, contra 3 níveis de `Vict Sex`.

Impacto. Na dissimilaridade de Hamming, um atributo com 5.717 níveis discorda em aproximadamente 94% dos pares de registros, tornando-se praticamente constante na função de custo. A AMI de `Mocodes` foi de 0,033 (Exp. 1) e 0,059 (Exp. 2): o campo com maior densidade informacional do conjunto foi o que menos contribuiu.

Correção. Binarizar `Mocodes` em 739 indicadores por token (`str.split()`), ou removê-lo do K-Modes e tratá-lo por método adequado a dados em formato de cesta.

E4 — Atributos redundantes e quase-constantes

O que ocorreu. A inclusão de `Crm Cd 1` a `Crm Cd 4` no Experimento 2 adicionou uma variável redundante e três praticamente constantes.

Impacto. - `Crm Cd 1` é idêntico a `Crm Cd` em 99,7% dos registros. Sua inclusão equivale a atribuir peso 2 ao tipo de crime — uma ponderação implícita e não intencional. - `Crm Cd 3` tem moda cobrindo 99,6% dos registros e AMI de 0,000; `Crm Cd 4` tem moda cobrindo 100,0% e contribui com 2 discordâncias em um custo total de 48.613. Atributos constantes adicionam apenas um deslocamento fixo ao custo e diluem o peso relativo dos atributos informativos.

Correção. Manter apenas `Crm Cd`; remover `Crm Cd 1`, `Crm Cd 3` e `Crm Cd 4`. `Crm Cd 2` deve migrar para a análise de coocorrência (PP1), onde tem função legítima, e sair do K-Modes.

E5 — Saídas obsoletas no notebook

O que ocorreu. As curvas de custo apresentadas foram geradas em sessão anterior à alteração do conjunto de atributos.

Evidência. O custo reportado em k=1 é 38.487. A decomposição desse custo por atributo — `AREA` 8.665 + `Crm Cd` 9.123 + `Mocodes` 9.371 + `Vict Sex` 5.061 + `Vict Descent` 6.267 — soma exatamente 38.487, correspondendo à configuração de **5 atributos**. Com os 9 atributos efetivamente utilizados no Experimento 2, o custo em k=1 seria 48.613. Adicionalmente, os avisos de execução de células distintas referenciam identificadores de kernel diferentes, confirmando que parte das saídas foi herdada da sessão anterior.

Impacto. A curva que fundamentou a escolha de k=7 descreve um espaço de atributos diferente daquele efetivamente utilizado. A escolha de k não está, portanto, sustentada pela evidência apresentada.

Correção. Reexecução completa em sessão limpa (*Restart and run all*), com `n_init` elevado para 20 ou mais, e regeração de todas as figuras a partir da configuração final de atributos.

Síntese

Código	Falha	Severidade	Status
E1	Amostragem não aleatória	Alta	A corrigir
E2	Exclusão desbalanceada de registros	Alta	A corrigir
E3	Cardinalidade desbalanceada	Alta	A corrigir
E4	Atributos redundantes/constantes	Média	A corrigir
E5	Saídas obsoletas	Alta	A corrigir

---

9. Limitações

9.1 Natureza do dado

Registros policiais medem **criminalidade notificada e registrada**, não criminalidade ocorrida. Três mecanismos afastam um do outro:

- **Subnotificação diferencial.** Nem toda vítima procura a polícia, e a propensão a notificar varia por tipo de crime, por perfil da vítima e por relação da comunidade com a instituição policial.
- **Viés de policiamento.** A distribuição espacial dos registros reflete, em parte, a distribuição do efetivo policial. Áreas mais patrulhadas geram mais registros para o mesmo nível de criminalidade subjacente.
- **Efeito de classificação.** A tipificação depende de decisão do agente que registra a ocorrência.

Toda conclusão do trabalho deve ser enunciada em termos de registros, não de criminalidade.

9.2 Uso de variáveis demográficas

O projeto utiliza `Vict Descent` e `Vict Sex` como variáveis de análise. Três esclarecimentos são necessários:

1. **As variáveis descrevem vítimas, não suspeitos.** O conjunto de dados não contém informação sobre autores de crimes. Nenhuma inferência sobre perfil de autoria é possível a partir dele.
2. **Não constituem variáveis explicativas de comportamento.** A distribuição demográfica observada reflete a composição demográfica dos territórios, combinada com os vieses de notificação e policiamento descritos em 9.1.
3. **Agrupamentos organizados por essas variáveis não são perfis criminais.** Quando o Experimento 1 produziu partições determinadas por ascendência, o resultado descreve a composição da base, não uma característica do crime. Reportá-lo como perfil seria incorreto do ponto de vista técnico e problemático do ponto de vista ético.

9.3 Limitações de escopo

- Cobertura restrita a 2020–fevereiro de 2024 para análises longitudinais (Seção 3).
- Ausência de denominador populacional por divisão policial impede o cálculo de taxas.
- Coordenadas anonimizadas em nível de quadra limitam a granularidade espacial.
- Ausência de dados socioeconômicos por território impede controle por variáveis de confusão.

---

10. Próximos passos

Etapa imediata — correção

1. Implementar as correções E1 a E5 (Seção 8).
2. Regerar a curva de custo com o conjunto final de atributos, `n_init  20`, e comparar `init='Cao'` e `init='Huang'`.
3. Reavaliar por AMI se a partição corrigida captura tipo de crime e modus operandi. Se a curva permanecer sem cotovelo — hipótese mais provável —, registrar formalmente a ausência de estrutura latente como resultado do trabalho.

Etapa seguinte — métodos adequados às perguntas

4. **PP1:** aplicar FP-Growth sobre o conjunto `{Crm Cd 1, ..., Crm Cd 4}` como transação, reportando suporte, confiança e *lift*.
5. **PP2:** consolidar a análise de V de Cramér com tratamento adequado da comparabilidade entre tabelas de dimensões distintas; complementar com análise de resíduos padronizados para identificar quais células específicas concentram a associação.
6. **`Mocodes`:** binarizar em 739 indicadores e explorar agrupamento sobre esse espaço, que é o mais promissor do conjunto para caracterização de modus operandi.

Extensão possível

7. Formular um problema supervisionado de classificação do desfecho (`Status Desc`: prisão *vs.* investigação em curso), com desbalanceamento de aproximadamente 9/91. A avaliação deve usar precisão-revocação, não acurácia.

---

11. Considerações finais

A entrega desta etapa não apresenta os perfis de crime que constavam do plano inicial. O que apresenta é um diagnóstico quantificado de por que o método escolhido não os produziu, e a identificação do caminho metodologicamente correto para as perguntas de pesquisa.

Três resultados consolidados sustentam a etapa:

1. A identificação da quebra estrutural de março de 2024, que invalidaria qualquer análise longitudinal do período completo e que não é sinalizada na documentação da fonte.
2. O diagnóstico, por informação mútua, de que as partições geradas refletiam composição demográfica e não perfil criminal — acompanhado da identificação das cinco causas técnicas.
3. Os resultados preliminares por V de Cramér e coocorrência, que já respondem parcialmente às duas perguntas de pesquisa e, em ambos os casos, contrariam as hipóteses iniciais.

Referências

Los Angeles Police Department. *Crime Data from 2020 to Present*. Los Angeles Open Data. Disponível em: https://data.lacity.org/Public-Safety/Crime-Data-from-2020-to-Present/2nrs-mtv8

HUANG, Z. Extensions to the k-Means Algorithm for Clustering Large Data Sets with Categorical Values. *Data Mining and Knowledge Discovery*, v. 2, n. 3, p. 283–304, 1998.

CAO, F.; LIANG, J.; BAI, L. A new initialization method for categorical data clustering. *Expert Systems with Applications*, v. 36, n. 7, p. 10223–10228, 2009.

CRAMÉR, H. *Mathematical Methods of Statistics*. Princeton University Press, 1946.

VINH, N. X.; EPPS, J.; BAILEY, J. Information Theoretic Measures for Clusterings Comparison. *Journal of Machine Learning Research*, v. 11, p. 2837–2854, 2010.

HAN, J.; PEI, J.; YIN, Y. Mining frequent patterns without candidate generation. *ACM SIGMOD Record*, v. 29, n. 2, p. 1–12, 2000.

Apêndice A — Ambiente e reprodutibilidade

Item	Especificação
Linguagem	Python 3
Bibliotecas	pandas, numpy, scipy, scikit-learn, kmodes 0.12.2, matplotlib, seaborn
Semente aleatória	42
Ambiente	Google Colab

Apêndice B — Decisões de tratamento

Decisão	Justificativa	Seção
Truncar série em 29/02/2024	Quebra estrutural por migração de sistema	3.4
`Vict Age = 0` como ausente	Sentinela, não idade real	4.2
Excluir `LAT/LON` = (0,0)	Sentinela de localização não informada	4.2
Tratar `X` como ausente	Código de "desconhecido"	4.2
Agregar `TIME OCC` em faixas	Arredondamento em 39,1% dos registros	4.3
Manter nulos estruturais	Ausência com significado; imputação seria incorreta	4.1