# LPAD Crimes — Relatório Técnico · Segunda Entrega

## Projeto Integrador III — Ciência de Dados e Machine Learning | CEUB

Integrantes:

Henrique Valle

Matheus Lopes

Italo Nascimento

Davi Amâncio

Outubro de 2026 — reestruturação do pipeline e validação do agrupamento

## Sumário

Sumário executivo ..... 2
1. Posição desta entrega ..... 3
2. Notebook 01 — Limpeza e preparação ..... 4
3. Notebook 02 — Agrupamento revisado ..... 6
4. Existe estrutura de agrupamento? ..... 8
5. A partição obtida em k = 6 ..... 10
6. Teste de reprodutibilidade ..... 12
7. PP2 — associação sem circularidade ..... 13
8. Modus operandi — o resultado mais promissor ..... 15
9. Notebook 03 — Visualizações ..... 16
10. Erros identificados nesta etapa ..... 19
11. Limitações ..... 22
12. Próximos passos ..... 22
13. Considerações finais ..... 23
Referências ..... 25
Apêndice A — Ambiente e reprodutibilidade ..... 25
Apêndice B — Cadeia de arquivos ..... 26
Apêndice C — Situação consolidada dos erros ..... 26

## Sumário executivo

Esta entrega dá continuidade ao Relatório Técnico Parcial, que havia identificado cinco falhas metodológicas (E1 a E5) nos primeiros experimentos de agrupamento e estabelecido um plano de correção.

O pipeline foi inteiramente reconstruído e dividido em **três notebooks encadeados** — limpeza, agrupamento e visualização. **As cinco correções previstas foram implementadas**, e a mais importante delas é conceitual: as variáveis demográficas da vítima deixaram de ser entrada do modelo e passaram a ser variáveis de descrição aplicadas depois do agrupamento. Isso elimina a circularidade que inviabilizava a leitura dos resultados anteriores.

Além das correções, foram incorporados instrumentos de validação que não existiam na etapa anterior: **modelo nulo por permutação**, silhueta com distância de Hamming, teste de estabilidade por reamostragem e detecção automática do cotovelo.

Esses instrumentos responderam à questão que o relatório parcial havia deixado formalmente em aberto, e a resposta é negativa: **os registros não formam agrupamentos naturais no espaço de atributos utilizado**. Em k=6, a redução de custo obtida nos dados reais é de 31,9%, contra 27,9% obtidos em dados com toda associação entre colunas destruída por embaralhamento — ou seja, **87% do desempenho do algoritmo é reproduzido por dados sem estrutura**. A silhueta fica em 0,080 e nenhum valor de k atingiu o limiar de estabilidade adotado.

A esse diagnóstico esta entrega acrescenta um achado novo, obtido por um teste de reprodutibilidade não previsto no plano original: **mantendo k, número de reinicializações e dados constantes, e variando apenas a semente aleatória, o ARI médio entre execuções é de 0,226**. A partição específica obtida não é reproduzível, e as leituras construídas sobre ela — perfis, ordenação de atributos, análise de sensibilidade — não sobrevivem a uma segunda execução.

A cadeia completa foi executada em sessão única e linear, com as saídas preservadas, o que permitiu auditar os números da limpeza e analisar as visualizações. Dois resultados vieram dessa execução:

**O sinal mais forte encontrado no projeto está na taxa de prisão por tipo de crime**, que varia de 0,0% a 36,2% — e que a partição não captura, comprimindo essa amplitude para a faixa de 7,0% a 16,6% entre clusters.

**A associação entre perfil do fato criminal e perfil demográfico da vítima é menor do que os coeficientes sugerem.** Mais da metade dela decorre das categorias que marcam ausência de vítima pessoa física, e não de padrões de vitimização.

Em contrapartida, o **agrupamento de modus operandi** (`Mocodes` tratado como texto, via TF-IDF, SVD e K-Means) apresenta silhueta de 0,40 e produz grupos substantivamente coerentes. É o resultado mais promissor do projeto até aqui e deve se tornar a linha principal da etapa final.

Este relatório documenta o que foi implementado, apresenta os resultados obtidos, identifica **seis novas falhas (E6 a E11)** — uma delas já resolvida no curso desta etapa — e estabelece o plano de correção correspondente.

---

## 1. Posição desta entrega

### 1.1 O que mudou desde o relatório parcial

O relatório anterior documentou dois experimentos de agrupamento que não produziram os perfis pretendidos, identificou as causas técnicas e definiu um plano de correção. Esta entrega executa esse plano e vai além dele em dois pontos: incorpora métricas de validação de agrupamento que não constavam do plano, e desenvolve o tratamento de `Mocodes` que estava previsto apenas como possibilidade.

### 1.2 Perguntas de pesquisa

As perguntas permanecem as mesmas:

**PP1 — Existem tipos de crime que ocorrem associados entre si?**

**PP2 — Existem associações entre tipo de crime, área geográfica e características demográficas das vítimas?**

O estado de cada uma ao final desta etapa é tratado nas Seções 7 e 8.

### 1.3 Arquitetura em três notebooks

O código monolítico anterior foi substituído por uma cadeia com contratos explícitos entre etapas:

```
01_limpeza.ipynb      → data/processed/lapd_clean.csv
02_clusterizacao.ipynb → data/processed/amostra_clusters.csv
                         (+ metricas_escolha_k.csv, associacao_clusters.
csv)
03_visualizacoes.ipynb → docs/figuras/*.png
```

Cada notebook verifica, por meio de `assert`, que a entrada recebida contém as colunas esperadas e respeita as decisões metodológicas da etapa anterior — por exemplo, o notebook 02 confirma que o corte temporal de 29/02/2024 foi efetivamente aplicado antes de prosseguir. Essa separação atende diretamente ao problema E5 da etapa anterior, em que saídas de sessões diferentes conviviam no mesmo arquivo.

---

## 2. Notebook 01 — Limpeza e preparação

### 2.1 Regras aplicadas

| # | Tratamento | Justificativa |
|---|---|---|
| 1 | Datas convertidas para `datetime`; `TIME OCC` (HHMM) compõe `DATETIME OCC` separado | Horários inválidos geram `NaT` apenas no campo combinado, preservando a data |
| 2 | **Corte em 29/02/2024** | Quebra estrutural da série pela migração ao NIBRS (relatório parcial, Seção 3) |
| 3 | Duplicatas de `DR_NO` removidas | `DR_NO` é a chave do registro |
| 4 | `Vict Age` fora do intervalo [1, 100] → ausente; `LAT/LON` = 0 → ausente | Valores sentinela, não medidas |
| 5 | **Nenhuma linha descartada por ausência estrutural**: sem sexo ou ascendência → `NAO_APLICAVEL`; `X`, `H`, `-` → `DESCONHECIDO`; local ausente → `NAO_INFORMADO` | Corrige E2 |
| 6 | `Weapon Used Cd` permanece ausente quando não há arma | Preencher com 0 faria o código cair na faixa de armas de fogo (< 200) |
| 7 | `Crm Cd 1` a `Crm Cd 4` consolidados em `Crm_Count`; removidas `LOCATION`, `Cross Street`, `Status Desc`, `TIME OCC` | Corrige E4 |
| 8 | Colunas derivadas `Week_OCC` e `shift_OCC` | Dia da semana e turno |

A regra 5 é a correção mais consequente. Na versão anterior, o `dropna` em `Mocodes`, `Vict Sex` e `Vict Descent` eliminava 15,1% da base e, dentro dela, 99,5% dos registros de `VEHICLE - STOLEN` — o crime mais frequente do conjunto. Convertendo a ausência em categoria explícita, nenhum registro é perdido por não ter vítima pessoa física identificada.

A regra 6 corrige um erro que teria passado despercebido: preencher `Weapon Used Cd` com zero colocaria todos os crimes sem arma na faixa numérica das armas de fogo, invertendo completamente a leitura do atributo.

### 2.2 Contrato de saída

O notebook exporta 24 colunas e verifica, antes de gravar, que não há nulos em `DR_NO`, `DATE OCC`, `Crm Cd`, `Crm Cd Desc`, `Vict Sex`, `Vict Descent`, `Premis Desc`, `Status` e `AREA NAME`; que a data máxima respeita o corte; e que `DR_NO` é único.

### 2.3 Resultado da execução

| Etapa | Resultado |
|---|---|
| Registros brutos | 1.004.894 |
| Sem data de ocorrência válida | 0 |
| Horários inválidos (`DATETIME OCC = NaT`) | 0 |
| Ocorrência posterior ao relato (inconsistência sinalizada) | 0 |
| **Corte em 29/02/2024** | 91.247 removidos → **913.647 registros** |
| Duplicatas de `DR_NO` | 0 |
| `Vict Age` fora de [1, 100] → ausente | 229.906 (25,2%) |
| `LAT/LON = 0` → ausente | 2.240 |
| **Base limpa** | **913.647 linhas × 24 colunas (90,9% da base bruta)** |

Três verificações de consistência passaram sem exceções: não há datas de ocorrência inválidas, não há horários fora do formato HHMM, e não há registro cuja ocorrência seja posterior ao relato. A ausência de duplicatas confirma que `DR_NO` é chave válida.

**Composição de `Vict Sex` após o tratamento:**

| Categoria | Registros |
|---|---|
| M | 374.716 |
| F | 334.355 |
| NAO_APLICAVEL (antes ausente) | 120.823 |
| DESCONHECIDO (antes `X`, `H`, `-`) | 83.753 |

Esses números quantificam o alcance da correção E2: **120.823 registros sem sexo informado e 127.234 sem `Mocodes` foram preservados como categoria explícita** em vez de descartados pelo `dropna` da versão anterior.

**Nulos remanescentes**, todos em campos onde a ausência tem significado:

| Coluna | Ausentes | Motivo |
|---|---|---|
| `Weapon Used Cd` / `Weapon Desc` | 598.432 | Crime sem arma |
| `Vict Age` | 229.906 | Sentinela convertido |
| `Mocodes` | 127.234 | Modus operandi não registrado |
| `LAT` / `LON` | 2.240 | Coordenada não informada |
| `Premis Cd` | 10 | Local não codificado |

Observação menor: como nenhum horário inválido foi encontrado, a categoria `SEM_HORA` prevista em `PERIODO` nunca é acionada. O tratamento defensivo é correto, mas o rótulo não aparece em nenhuma figura.

---

## 3. Notebook 02 — Agrupamento revisado

### 3.1 Situação das correções previstas

| Código | Falha da etapa anterior | Correção implementada | Situação |
|---|---|---|---|
| **E1** | `[:10000]` — as 10 mil primeiras linhas, todas de 2020 | Amostra aleatória única de 50.000 registros com `random_state=42` | Corrigido |
| **E2** | `dropna` eliminava 99,5% de `VEHICLE - STOLEN` | Ausências estruturais viram categorias explícitas | Corrigido |
| **E3** | `Mocodes` como cadeia única (5.717 níveis) dominava a distância de Hamming | `Mocodes` retirado do K-Modes e tratado como texto em análise própria | Corrigido |
| **E4** | `Crm Cd 1` redundante com `Crm Cd`; `Crm Cd 3` e `Crm Cd 4` quase constantes | Um único atributo por conceito | Corrigido |
| **E5** | Curvas geradas em sessão anterior à mudança de atributos | Notebook linear, com `assert` de contrato entre etapas; cadeia reexecutada de ponta a ponta em sessão única | Corrigido |

Além dessas, o notebook corrigiu erros de código remanescentes da versão anterior: o gráfico rotulado “Crm Cd 1 por Cluster” que usava o DataFrame errado, o título “Crm Cd 3” sobre o gráfico de `Crm Cd 2`, e a matriz de V de Cramér que dividia por zero em tabelas degeneradas.

### 3.2 A correção conceitual

A mudança mais importante não estava na lista E1–E5. Na etapa anterior, `Vict Sex` e `Vict Descent` eram **entrada** do K-Modes, e o diagnóstico por informação mútua mostrou que a partição resultante era determinada por elas. O resultado era circular: as variáveis demográficas foram fornecidas ao algoritmo e ele devolveu grupos demográficos.

A versão atual separa os atributos em dois conjuntos:

| Conjunto | Variáveis | Papel |
|---|---|---|
| **Formadores** | `CRIME`, `LOCAL`, `ARMA`, `PERIODO`, `DIA` | Entram no K-Modes — descrevem o **fato criminal** |
| **Descritivos** | `AREA_NOME`, `SEXO_VIT`, `ASCEND_VIT`, `FAIXA_IDADE`, `PRISAO`, `ANO` | Aplicados **depois**, sobre a partição pronta |

Com isso, qualquer associação encontrada entre a partição e o perfil da vítima passa a ser uma associação real entre perfil do fato e perfil da vítima, e não um reflexo da própria entrada. É essa separação que torna a resposta a PP2 (Seção 7) metodologicamente válida.

### 3.3 Atributos de entrada

A agregação foi desenhada para manter a cardinalidade comparável entre atributos, evitando a reincidência de E3:

| Atributo | Construção | Níveis | Moda | Moda cobre |
|---|---|---|---|---|
| `CRIME` | 25 tipificações mais frequentes + `OUTROS` | 26 | VEHICLE - STOLEN | 10,4% |
| `LOCAL` | 15 locais mais frequentes + `OUTROS` | 16 | STREET | 25,2% |
| `ARMA` | Famílias de código do LAPD | 6 | SEM_ARMA | 65,4% |
| `PERIODO` | Faixas do dia | 4 | TARDE | 32,5% |
| `DIA` | Dia útil / fim de semana | 2 | DIA_UTIL | 71,6% |

A agregação de `ARMA` segue as faixas de código do LAPD (1xx fogo, 2xx branca, 3xx objeto, 400 força física, 5xx outros) e foi conferida no próprio notebook contra as descrições textuais, o que é uma boa prática: a família `FORCA_FISICA` contém exclusivamente `STRONG-ARM (HANDS, FIST, FEET OR BODILY FORCE)`, como esperado.

A faixa de `PERIODO` responde ao viés de arredondamento documentado no relatório parcial (39,1% dos horários terminam em `:00`), que torna a análise horária fina pouco confiável.

Permanece um desequilíbrio de cardinalidade entre 26 níveis (`CRIME`) e 2 níveis (`DIA`). Na dissimilaridade de Hamming, um atributo binário pode ser quase perfeitamente reproduzido por uma partição, enquanto um atributo com 26 níveis não pode. As consequências disso aparecem na Seção 6.

### 3.4 Instrumentos de validação incorporados

| Instrumento | Pergunta que responde |
|---|---|
| **Modelo nulo por permutação** | A redução de custo é maior do que a obtida em dados sem estrutura? |
| **Silhueta (Hamming)** | Os registros estão mais próximos do próprio grupo do que do vizinho? |
| **Estabilidade (ARI)** | A partição se repete com outra subamostra e outra semente? |
| **Cotovelo automático** | Onde está o joelho da curva, sem leitura visual? |

O modelo nulo é a adição mais relevante. Ele embaralha cada coluna de forma independente: as frequências marginais de cada categoria permanecem idênticas, mas toda associação entre colunas é destruída. Se o algoritmo reduz o custo nos dados reais tanto quanto nos embaralhados, a partição está apenas fatiando distribuições marginais, e não encontrando grupos.

É o teste formal que o relatório parcial havia deixado em aberto ao constatar que a curva de custo não tinha cotovelo.

---

## 4. Existe estrutura de agrupamento?

### 4.1 Modelo nulo por permutação

| k | Redução real | Redução no nulo | Ganho | Silhueta | ARI |
|---|---|---|---|---|---|
| 2 | 0,146 | 0,111 | 0,035 | 0,112 | **0,578** |
| 3 | 0,209 | 0,168 | 0,041 | 0,112 | 0,309 |
| 4 | 0,261 | 0,194 | 0,067 | 0,116 | 0,218 |
| 5 | 0,286 | 0,243 | 0,044 | 0,097 | 0,271 |
| **6** | **0,319** | **0,279** | **0,041** | **0,080** | **0,227** |
| 7 | 0,341 | 0,296 | 0,045 | 0,096 | 0,262 |

| k | Redução real | Redução no nulo | Ganho | Silhueta | ARI |
|---|---|---|---|---|---|
| 8 | 0,365 | 0,307 | 0,058 | 0,107 | 0,206 |
| 9 | 0,373 | 0,329 | 0,044 | 0,110 | 0,223 |
| 10 | 0,385 | 0,336 | 0,049 | 0,095 | 0,236 |
| 11 | 0,402 | 0,339 | 0,064 | 0,069 | 0,225 |
| 12 | 0,426 | 0,350 | **0,077** | 0,089 | 0,199 |

Em k=6, a razão entre a redução obtida no nulo e a obtida nos dados reais é de 0,279 / 0,319 = **87,5%**. Em termos diretos: de cada dez pontos de redução de custo que o K-Modes alcança, quase nove seriam alcançados sobre dados em que nenhuma coluna guarda relação com as demais.

O ganho sobre o nulo não cresce de forma ordenada com k — oscila entre 0,035 e 0,077 sem tendência clara, o que é o comportamento esperado quando não há estrutura a encontrar.

### 4.2 Silhueta

A silhueta com distância de Hamming permanece entre 0,069 e 0,116 em toda a faixa testada. Valores dessa ordem indicam agrupamentos essencialmente sobrepostos: a distância média de um registro ao próprio grupo é quase igual à distância ao grupo vizinho mais próximo.

Para referência, o mesmo instrumento aplicado ao agrupamento de modus operandi (Seção 8) devolve 0,40.

### 4.3 Estabilidade

O teste ajusta o modelo em subamostras de 80% com sementes distintas e compara as partições resultantes por ARI. O limiar adotado foi 0,6.

**Nenhum valor de k atingiu o limiar.** O mais alto foi k=2, com 0,578 — e, como o próprio notebook registra em sua regra de decisão, k=2 tende a ser o mais estável simplesmente por ser a partição mais grosseira possível. Em k=6, o ARI é de 0,227.

### 4.4 Escolha de k

A regra de decisão implementada é: entre os valores de k com partição estável (ARI ≥ 0,6), escolher o de maior ganho sobre o modelo nulo; se nenhum for estável, usar o joelho da curva e **reportar o resultado como ausência de estrutura robusta**.

A execução acionou o segundo ramo:

```
K_FINAL = 6 (nenhum k estável; usado o joelho da curva); init = Huang
Ganho sobre o nulo em k=6: 0.041 | silhueta: 0.080 | ARI: 0.23
```

É importante que isso fique explícito na apresentação do trabalho: **k=6 não foi escolhido por ser um bom valor, mas porque nenhum valor era**. A verificação de convergência, por outro lado, passou — o custo é não-crescente em k em toda a faixa, o que confirma que o aumento de `n_init` corrigiu a instabilidade numérica observada na etapa anterior com `init='Huang'` e `n_init=5`.

### 4.5 Veredito

As quatro evidências convergem: **os registros de ocorrência do LAPD não formam agrupamentos naturais no espaço de atributos do fato criminal**. A partição obtida é uma fatia descritiva da base, não uma estrutura latente descoberta.

Esse é um resultado válido e deve ser apresentado como tal. Ele responde formalmente à questão que o relatório parcial havia levantado e decorre de um procedimento de teste explícito, não de uma impressão visual sobre a curva de custo.

---

## 5. A partição obtida em k = 6

Apesar do veredito acima, a partição foi caracterizada, tanto para documentar o procedimento quanto porque a descrição dos grupos tem valor exploratório. As leituras desta seção devem ser lidas junto com a Seção 6, que mostra que elas não são reproduzíveis.

### 5.1 Composição

| Cluster | n | % | CRIME (centroide) | LOCAL (centroide) | ARMA | PERÍODO | DIA |
|---|---|---|---|---|---|---|---|
| 0 | 13.039 | 26,1% | VEHICLE - STOLEN | STREET | SEM_ARMA | MANHA | FIM_DE_SEMANA |
| 1 | 8.898 | 17,8% | INTIMATE PARTNER - SIMPLE ASSAULT | MULTI-UNIT DWELLING | FORCA_FISICA | TARDE | DIA_UTIL |
| 2 | 2.565 | 5,1% | BATTERY - | PARKING LOT | FORCA_FISICA | TARDE | FIM_DE_SEMANA |

| Cluster | n | % | CRIME (centroide) | LOCAL (centroide) | ARMA | PERÍODO | DIA |
|---|---|---|---|---|---|---|---|
| | | | SIMPLE ASSAULT | | | | |
| 3 | 11.830 | 23,7% | VEHICLE - STOLEN | STREET | SEM_ARMA | NOITE | DIA_UTIL |
| 4 | 6.694 | 13,4% | BURGLARY | SINGLE FAMILY DWELLING | SEM_ARMA | MADRUGADA | DIA_UTIL |
| 5 | 6.974 | 13,9% | OUTROS | OUTROS | SEM_ARMA | TARDE | DIA_UTIL |

Os clusters **0 e 3 têm centroide idêntico nos três atributos que descrevem o fato** (`VEHICLE - STOLEN` / `STREET` / `SEM_ARMA`) e diferem apenas em quando o crime ocorreu. Juntos somam **49,8% da amostra**. Metade da partição, portanto, é o mesmo tipo de ocorrência fatiada por horário e dia da semana.

### 5.2 Pureza dos centroides

A pureza é a fração do cluster cujo valor coincide com o do centroide naquele atributo. Um centroide com pureza baixa é uma moda fraca e não descreve o grupo.

| Cluster | CRIME | LOCAL | ARMA | PERIODO | DIA |
|---|---|---|---|---|---|
| 0 | **0,16** | 0,38 | 0,79 | 0,46 | 0,73 |
| 1 | 0,26 | 0,37 | 0,70 | 0,49 | 0,90 |
| 2 | 0,52 | 0,24 | 0,73 | 0,49 | 0,94 |
| 3 | 0,26 | 0,52 | 0,83 | 0,73 | 1,00 |
| 4 | 0,28 | 0,60 | 0,86 | 0,50 | 0,91 |
| 5 | 0,29 | 0,60 | 0,85 | 0,74 | 0,88 |

O centroide do cluster 0 é `VEHICLE - STOLEN`, mas apenas **16% do cluster** é efetivamente furto de veículo. A pureza de `CRIME` só passa de 0,30 no cluster 2, o menor de todos (5,1% da amostra).

O roteiro de leitura do próprio notebook estabelece que um cluster só deve ser nomeado como "perfil" se a pureza do atributo principal for alta. Pelo critério, **cinco dos seis clusters não qualificam**. Ver E8.

### 5.3 Perfis por lift

A visualização por barras empilhadas da etapa anterior foi substituída por análise de *lift*, definido como a razão entre a frequência de uma categoria dentro do cluster e sua frequência na base — isto é, `lift(c, g) = P(c | g) / P(c)`. Um lift de 3 indica que a categoria é três vezes mais comum no grupo do que no conjunto.

É uma melhoria metodológica real: a contagem absoluta era dominada pelas categorias mais frequentes da base, enquanto o lift revela o que distingue cada grupo. Os destaques mais marcantes:

| Cluster | Destaques por lift |
|---|---|
| 1 | INTIMATE PARTNER - SIMPLE ASSAULT (5,1×, 26% do cluster); FORCA_FISICA (3,8×, 70%) |
| 2 | BATTERY - SIMPLE ASSAULT (6,5×, 52%); PARKING LOT (3,4×, 24%) |
| 4 | BURGLARY (4,6×, 28%); SINGLE FAMILY DWELLING (3,6×, 60%); MADRUGADA (3,2×, 50%) |

Os clusters 1, 2 e 4 apresentam lifts substantivos. Os clusters 0, 3 e 5 têm lifts majoritariamente abaixo de 2,5 e são pouco distinguíveis da base.

---

## 6. Teste de reprodutibilidade

Esta seção apresenta uma verificação que não constava do plano de correção e que, na avaliação da equipe, é o achado metodológico mais importante desta etapa.

### 6.1 Protocolo

O K-Modes foi executado cinco vezes sobre a **mesma amostra**, com o **mesmo k (6)** e o **mesmo número de reinicializações (`n_init=10`)**, variando exclusivamente a semente aleatória. Compararam-se os custos finais, a ordenação dos atributos por informação mútua e o ARI entre pares de execuções.

### 6.2 Resultados

| Semente | Custo | Atributo de maior AMI | AMI de DIA |
|---|---|---|---|
| 42 | 102.243 | PERIODO (0,322) | 0,052 |
| 7 | 101.098 | CRIME (0,215) | 0,134 |
| 123 | 101.280 | PERIODO (0,249) | 0,196 |
| 2024 | 99.420 | PERIODO (0,389) | 0,071 |
| 99 | 101.231 | PERIODO (0,247) | 0,140 |

O custo varia apenas 2,8% entre a melhor e a pior execução. O ARI entre pares, porém, vai de 0,124 a 0,411, com **média de 0,226**.

### 6.3 Consequências

**As partições são quase não relacionadas entre si, apesar de terem custo praticamente equivalente.** O K-Modes está encontrando uma família de soluções de qualidade similar e mutuamente inconsistentes — comportamento esperado em um espaço sem estrutura de agrupamento, e consistente com o ARI de 0,227 já medido pelo teste de estabilidade do próprio notebook.

Isso tem duas implicações diretas sobre as leituras da Seção 5 e sobre a figura `04_ami` do notebook:

**A ordenação dos atributos não é estável.** Na execução registrada no notebook, `DIA` aparece como o atributo que mais formou a partição (AMI 0,247), acima de `CRIME` (0,178). Nas cinco execuções acima, `PERIODO` lidera em quatro, `CRIME` em uma, e o AMI de `DIA` varia entre 0,052 e 0,196. Qualquer afirmação do tipo "o agrupamento foi determinado principalmente pelo dia da semana" descreve uma execução, não uma propriedade dos dados.

**Os perfis da Seção 5 são específicos de uma execução.** Outra semente produziria seis grupos diferentes, com destaques por lift diferentes, ao mesmo custo. Os perfis devem ser apresentados como ilustração do procedimento, não como achado.

---

## 7. PP2 — associação sem circularidade

Como as variáveis demográficas não entraram no modelo, a associação medida entre a partição e cada variável descritiva não é circular.

| Variável descritiva | V de Cramér | AMI |
|---|---|---|
| `SEXO_VIT` | 0,252 | 0,074 |
| `ASCEND_VIT` | 0,205 | 0,067 |

| Variável descritiva | V de Cramér | AMI |
|---|---|---|
| FAIXA_IDADE | 0,153 | 0,039 |
| PRISAO | 0,117 | 0,006 |
| AREA_NOME | **0,065** | 0,005 |
| ANO | 0,018 | 0,000 |

### 7.1 A área geográfica é a variável menos associada

Com V = 0,065, AREA_NOME fica abaixo de todas as demais. Isso confirma, por caminho independente, o achado do relatório parcial, que havia medido V = 0,090 entre tipo de crime e divisão policial diretamente. **As divisões do LAPD não se especializam em tipos de crime.**

O mapa de calor de área por cluster (Seção 9) torna o resultado visualmente inequívoco: a matriz de 6 × 21 células é quase inteiramente composta de valores entre 0,9 e 1,1. Os clusters 0 e 3, que somam metade da amostra, não desviam da média em nenhuma das 21 divisões.

As poucas exceções têm explicação por uso do solo, não por especialização criminal. O cluster 4 (arrombamento em residência unifamiliar) é sub-representado em Central (0,5×) e sobre-representado em Devonshire (1,4×), Foothill (1,3×) e West LA (1,3×) — exatamente a diferença entre a região central e os bairros residenciais horizontais. O cluster 5 (furto em comércio) é sub-representado em 77th Street (0,5×) e Southeast (0,6×).

### 7.2 A associação demográfica é inflada por categorias estruturais

SEXO_VIT (0,252) e ASCEND_VIT (0,205) aparecem como as associações mais fortes, o que à primeira vista sugere que o perfil do fato criminal se relaciona ao perfil de quem é vitimado. Os mapas de calor produzidos pelo notebook 03 mostram que a leitura é mais sutil.

No mapa de sexo da vítima, as categorias reais variam pouco entre clusters — M fica entre 0,9× e 1,3×, e F entre 0,7× e 1,5×. Já NAO_APLICAVEL varia de **0,0× a 2,4×**: está completamente ausente dos clusters 1, 2 e 4 (violência interpessoal) e fortemente concentrada no cluster 3 (furto de veículo). O padrão se repete em ascendência, onde as categorias étnicas ficam entre 0,4× e 1,6× enquanto NAO_APLICAVEL vai de 0,0× a 2,4× e DESCONHECIDO de 0,4× a 2,3×.

Em outras palavras, boa parte do que o coeficiente mede não é "este tipo de crime vitimiza este grupo", e sim **"este tipo de crime não tem vítima pessoa física"**.

A verificação quantitativa confirma. Recalculando o V de Cramér apenas sobre os registros com vítima efetivamente identificada — isto é, excluindo NAO_APLICAVEL e DESCONHECIDO, que somam 22,1% e 23,0% da amostra respectivamente:

| Par de variáveis | Completo | Só vítimas identificadas | Queda |
|---|---|---|---|
| `CRIME` × `SEXO_VIT` | 0,601 | 0,266 | 56% |
| `CRIME` × `ASCEND_VIT` | 0,377 | 0,144 | 62% |
| `CLUSTER` × `SEXO_VIT` | 0,277 | 0,117 | 58% |
| `CLUSTER` × `ASCEND_VIT` | 0,221 | 0,074 | 67% |

Os pares com `CRIME` não dependem da partição e são portanto exatamente reproduzíveis. Os pares com `CLUSTER` foram obtidos em execução independente e diferem em terceira casa dos valores da tabela anterior, pelo motivo exposto na Seção 6.

**Mais da metade da associação demográfica medida desaparece quando se consideram apenas registros com vítima real.** Restrita a esses, a associação entre perfil do fato e ascendência da vítima cai a 0,074 — abaixo da já fraca associação com a área geográfica.

Essa qualificação é relevante para a resposta a PP2 e está registrada como E11.

### 7.3 Leitura consolidada de PP2

Considerando 7.1 e 7.2 em conjunto: **nem a área geográfica nem o perfil demográfico da vítima diferenciam substancialmente os perfis de fato criminal**. A associação aparente com sexo e ascendência decorre majoritariamente de quais tipos de crime têm vítima pessoa física registrada, e não de padrões de vitimização.

Ressalva de método: como a partição não é reproduzível (Seção 6), os coeficientes exatos variam entre execuções. O que deve ser reportado é a ordenação e a magnitude aproximada, não os valores com três casas decimais.

**Quanto a PP1**, a resposta continua sendo a análise de coocorrência entre tipificações apresentada no relatório parcial. A formalização por FP-Growth, com suporte, confiança e *lift*, permanece pendente.

---

## 8. Modus operandi — o resultado mais promissor

O campo `Mocodes` passou a ser tratado como texto, conforme previsto no plano de correção:

1. cada código de quatro dígitos vira um *token*;
2. **TF-IDF** reduz o peso de códigos muito frequentes;
3. **SVD truncado** reduz a 20 dimensões;
4. **K-Means** com escolha de k por silhueta de cosseno.

### 8.1 Resultados

| Indicador | Valor |
|---|---|
| Registros com `Mocodes` | 86,3% |
| Vocabulário mantido (≥ 0,5% dos registros) | 97 códigos |
| Variância explicada pelo SVD | 55,8% |
| Silhueta no k escolhido | **0,40** |

A silhueta de 0,40 contrasta com os 0,080 do K-Modes sobre os atributos do fato. Os grupos resultantes são substantivamente coerentes:

| Cluster | n | Composição por tipo de crime |
|---|---|---|
| MO_4 | 2.294 | **95% THEFT OF IDENTITY** |
| MO_1 | 4.183 | 58% intimate partner simples + 15% agravada |
| MO_6 | 3.539 | 56% vandalismo felony + 25% misdemeanor |
| MO_5 | 4.299 | 58% battery + 20% assault with deadly weapon |

O ARI entre os dois agrupamentos é de **0,058** e o AMI de 0,102: eles capturam fenômenos distintos, e o de modus operandi captura o que interessa às perguntas de pesquisa.

### 8.2 Avaliação

Este é o resultado mais forte do projeto até aqui, e está sendo tratado como seção secundária do notebook de clusterização. A recomendação desta entrega é que **a análise de modus operandi se torne a linha principal da etapa final**, com o K-Modes mantido como contraponto metodológico — o caso em que o método não encontra estrutura, documentado com a evidência que o demonstra.

Há, contudo, um problema de execução a corrigir antes (E9).

---

## 9. Notebook 03 — Visualizações

O terceiro notebook consome exclusivamente os CSVs exportados pelo notebook 02 e não refaz nenhum agrupamento. Está organizado em torno de quatro perguntas — *o quê*, *quando*, *quem* e *onde* — e produz 18 figuras.

O desenho separa produção de resultados de produção de figuras, fixa a ordem de categorias ordinais (período do dia, dia da semana, faixa etária) para que os mapas de calor sejam legíveis, e degrada graciosamente quando as coordenadas não estão disponíveis.

A cadeia completa foi executada em sessão única e linear, com as saídas preservadas. Das 50.000 ocorrências da amostra, **49.907 (99,8%) têm coordenadas válidas** para o mapa.

### 9.1 Desfecho por cluster e por tipo de crime

| Cluster | n | % | Taxa de prisão | Crime mais sobre-representado |
|---|---|---|---|---|
| 0 | 13.039 | 26,1% | 8,0% | THEFT FROM MOTOR VEHICLE - PETTY (1,6×) |
| 1 | 8.898 | 17,8% | **16,6%** | INTIMATE PARTNER - SIMPLE ASSAULT (5,1×) |
| 2 | 2.565 | 5,1% | 12,0% | BATTERY - SIMPLE ASSAULT (6,5×) |
| 3 | 11.830 | 23,7% | **7,0%** | VEHICLE - STOLEN (2,5×) |
| 4 | 6.694 | 13,4% | 7,9% | BURGLARY (4,6×) |
| 5 | 6.974 | 13,9% | 8,3% | SHOPLIFTING - PETTY THEFT (3,4×) |

A taxa de prisão varia de 7,0% a 16,6% entre clusters — amplitude modesta, coerente com o V de Cramér de 0,117 medido na Seção 7.

A mesma variável desagregada **por tipo de crime** revela amplitude muito maior, de 0,0% a 36,2%:

| Faixa | Tipos de crime |
|---|---|
| **20% a 36%** | INTIMATE PARTNER - AGGRAVATED ASSAULT (36,2%); ASSAULT WITH DEADLY WEAPON (22,1%); INTIMATE PARTNER - SIMPLE ASSAULT (21,4%); ROBBERY (20,4%); CRIMINAL THREATS (20,4%) |
| **10% a 20%** | BRANDISH WEAPON (19,1%); VIOLATION OF RESTRAINING ORDER (16,9%); OTHER MISCELLANEOUS CRIME (12,2%); SHOPLIFTING (10,9%); VANDALISM - FELONY (10,9%) |
| **abaixo de 10%** | BURGLARY (9,8%); BATTERY - SIMPLE ASSAULT (7,0%); VEHICLE - STOLEN (5,0%); THEFT-GRAND (3,3%); BURGLARY FROM VEHICLE (1,8%); THEFT OF IDENTITY (0,8%); BIKE - STOLEN (0,0%) |

O padrão é nítido e tem explicação direta: **crimes de violência interpessoal têm autor conhecido ou presente no local; crimes patrimoniais, não.** A média geral é de 9,5%.

Este é o sinal mais forte encontrado em todo o projeto, e ele **não é capturado pela partição**: os clusters misturam tipos de crime com taxas de prisão muito distintas, comprimindo uma amplitude de 36 pontos percentuais em uma de 10. É mais um indício de que os agrupamentos borram estrutura em vez de revelá-la, e é o principal argumento a favor do problema supervisionado proposto na Seção 12.

### 9.2 O que efetivamente separa os clusters

Os mapas de calor de período do dia e dia da semana tornam visível o que a Seção 6 havia mostrado numericamente.

No mapa de **dia da semana**, o cluster 3 tem lift 0,0× em sábado e domingo e 1,4× em todos os dias úteis — é uma fatia puramente de dia útil. Os clusters 0 e 2 são o espelho: 2,5×–3,4× no fim de semana contra 0,1×–0,4× nos dias úteis. Três dos seis grupos são definidos primariamente pela divisão binária da semana.

No mapa de **período do dia**, o padrão se repete: cluster 3 com `MANHA` em 0,0× e `NOITE` em 2,4×; cluster 4 com `MADRUGADA` em 3,2× e `NOITE` em 0,1×; cluster 5 com `TARDE` em 2,3× e os extremos do dia em 0,1×.

Os dois atributos temporais fatiam a amostra de forma limpa, enquanto o tipo de crime segue apenas frouxamente. É a consequência previsível do desequilíbrio de cardinalidade descrito na Seção 3.3: na distância de Hamming, um atributo de 2 ou 4 níveis pode ser quase perfeitamente reproduzido por uma partição de 6 grupos, enquanto um de 26 níveis não pode. O otimizador gasta os clusters nos atributos baratos.

### 9.3 Estabilidade temporal e distribuição espacial

A participação mensal de cada cluster permanece **estável ao longo de todo o período** de janeiro de 2020 a fevereiro de 2024. Nenhum dos seis grupos cresce ou encolhe de forma sistemática; as séries oscilam em torno da própria média, com exceção de um declínio suave do cluster 1 (de cerca de 20% para 16%) e de um pico isolado do cluster 0 em setembro de 2022.

Esse resultado valida a decisão de corte da Seção 3 do relatório parcial: dentro da janela truncada, a composição da base não apresenta deriva residual. A quebra estava de fato concentrada na migração de sistema, e não em mudança gradual do fenômeno.

Os mapas de densidade espacial por cluster são **visualmente quase indistinguíveis entre si**: todos reproduzem a mesma silhueta urbana e as mesmas concentrações. A única diferença perceptível é uma dispersão ligeiramente maior do cluster 4 (arrombamento residencial) em direção ao Vale de San Fernando. A figura confirma de forma direta o V de Cramér de 0,065 da Seção 7.

### 9.4 Modus operandi dentro dos clusters

O mapa de calor cruzando os doze clusters de modus operandi com os seis clusters K-Modes mostra correspondências localizadas e fortes: MO_1 concentra-se no cluster 1 (3,4×), MO_5 no cluster 2 (4,2×), MO_4 no cluster 4 (2,8×) e MO_9 no cluster 5 (3,0×). Fora dessas células, a maior parte da matriz fica próxima de 1,0.

Ou seja: alguns agrupamentos de modus operandi correspondem a perfis de fato criminal, mas a maioria se distribui de forma independente da partição — coerente com o ARI de 0,058 entre os dois agrupamentos. Os dois métodos enxergam recortes distintos da mesma base.

---

## 10. Erros identificados nesta etapa

Seguindo a numeração do relatório parcial, que foi até E5.

### E6 — Partição não reproduzível entre execuções

**Descrição.** Mantidos os dados, k e `n_init`, a variação da semente aleatória produz partições mutuamente inconsistentes.

**Evidência.** Cinco execuções com k=6 e `n_init=10`: custos entre 99.420 e 102.243 (variação de 2,8%); ARI entre pares de 0,124 a 0,411, média de 0,226. O atributo de maior AMI alterna entre `PERIODO` e `CRIME`.

**Impacto.** Invalida como achado tudo o que é lido sobre a partição específica: os seis perfis da Seção 5, a ordenação de atributos da figura `04_ami` e a análise de sensibilidade da Seção 8 do notebook.

**Correção.** Elevar `N_INIT` de 10 para 50 ou mais e reportar a dispersão entre sementes como figura própria, em vez de apresentar uma execução única. A instabilidade é informação sobre os dados e merece ser exibida, não suprimida.

### E7 — Análise de sensibilidade indistinguível de ruído

**Descrição.** A análise de exclusão de atributo (*leave-one-feature-out*) compara o ARI entre a partição completa e a partição sem cada atributo, mas os valores obtidos estão dentro da faixa de variação produzida apenas pela troca de semente.

**Evidência.** ARI de exclusão: `ARMA` 0,182; `DIA` 0,203; `PERIODO` 0,261; `LOCAL` 0,305; `CRIME` 0,459. ARI entre execuções com configuração idêntica: 0,124 a 0,411. As faixas se sobrepõem quase integralmente.

**Impacto.** Não é possível distinguir "a remoção deste atributo alterou a partição" de "o algoritmo convergiu para outro ótimo local". A tabela não suporta conclusão sobre importância relativa de atributos.

**Correção.** Repetir cada configuração com várias sementes e comparar a distribuição de ARI da exclusão contra a distribuição de referência obtida sem remover atributo algum. Usar o mesmo `n_init` nos dois lados — atualmente a sensibilidade usa `n_init=3` contra `n_init=10` do modelo final.

### E8 — Pureza insuficiente para nomear perfis

**Descrição.** Os centroides são apresentados como caracterização dos clusters, mas a pureza do atributo `CRIME` é baixa demais para sustentar a leitura.

**Evidência.** Pureza de `CRIME` por cluster: 0,16; 0,26; 0,52; 0,26; 0,28; 0,29. O cluster 0, rotulado `VEHICLE - STOLEN`, tem 16% de furto de veículo. Os clusters 0 e 3 compartilham centroide idêntico em `CRIME`, `LOCAL` e `ARMA`, somando 49,8% da amostra.

**Impacto.** Nomear os grupos pelo centroide transmite uma homogeneidade que não existe. O risco é apresentar como "perfil criminal" o que é uma moda fraca sobre um grupo heterogêneo.

**Correção.** Adotar um critério numérico explícito — por exemplo, só nomear o cluster pelo centroide quando a pureza do atributo exceder 0,50 — e apresentar os demais pela distribuição, não pelo rótulo.

### E9 — Busca de k truncada no limite da faixa (modus operandi)

**Descrição.** O k do agrupamento de modus operandi é escolhido por silhueta máxima sobre `range(2, 13)`, e o máximo ocorre exatamente em k=12, o limite superior da faixa.

**Evidência.** A curva de silhueta é crescente em todo o trecho final (0,33 em k=9; 0,38 em k=10; 0,39 em k=11; 0,40 em k=12) e não apresenta inflexão. O ótimo está fora da faixa testada.

**Impacto.** O valor `K_MO = 12` é um artefato do limite de busca, não um ótimo. O agrupamento mais promissor do projeto está sendo avaliado com um parâmetro escolhido arbitrariamente.

**Correção.** Estender a busca para `range(2, 31)` e reexaminar. Se a silhueta continuar crescendo, investigar se a estrutura é hierárquica, caso em que um método aglomerativo pode ser mais adequado que o K-Means.

### E10 — Notebooks sem execução registrada · resolvido durante esta etapa

**Descrição.** Na primeira versão entregue, o notebook 03 não tinha nenhuma célula executada e, no notebook 01, as células de limpeza (14 a 21) estavam sem saída, o que impedia auditar os números do tratamento.

**Resolução.** A cadeia foi executada integralmente em sessão única e linear, com contadores de execução contínuos de 1 a 58 e saídas preservadas. Os números da limpeza passaram a constar da Seção 2.3 e os resultados das visualizações, da Seção 9.

**Pendência residual.** A execução foi feita em um arquivo único, com os três notebooks concatenados. A documentação (`LEIA-ME.md`) e a estrutura do repositório descrevem três

arquivos separados. É preciso decidir entre versionar o notebook combinado ou redividi-lo em três com as saídas preservadas, e alinhar a documentação à escolha.

### E11 — Associação demográfica inflada por categorias estruturais

**Descrição.** O V de Cramér entre a partição e as variáveis de vítima é calculado sobre todas as categorias, incluindo `NAO_APLICAVEL` e `DESCONHECIDO`, que não são grupos demográficos e sim marcações de ausência. Isso superestima a associação entre perfil do fato criminal e perfil da vítima.

**Evidência.** As categorias estruturais somam 22,1% dos registros em `SEXO_VIT` e 23,0% em `ASCEND_VIT`. Restringindo o cálculo aos registros com vítima identificada, `CRIME` × `SEXO_VIT` cai de 0,601 para 0,266 (−56%) e `CRIME` × `ASCEND_VIT` de 0,377 para 0,144 (−62%). Nos mapas de calor, as categorias demográficas reais variam entre 0,4× e 1,6×, enquanto `NAO_APLICAVEL` varia de 0,0× a 2,4×.

**Impacto.** Afeta diretamente a resposta a PP2. O coeficiente completo sugere associação moderada entre perfil do fato e demografia da vítima; a versão restrita mostra que mais da metade dessa associação é, na verdade, o reflexo de quais crimes têm vítima pessoa física registrada.

**Correção.** Reportar sempre os dois coeficientes lado a lado, ou tratar `NAO_APLICAVEL` como registro fora do escopo da análise demográfica. Vale também separar `NAO_APLICAVEL` (ausência estrutural, crime sem vítima pessoal) de `DESCONHECIDO` (vítima existe mas não foi caracterizada): são fenômenos distintos que hoje são agregados na mesma leitura.

### 10.1 Observação adicional sobre o modelo nulo

O modelo nulo é ajustado com `n_init=3`, enquanto o modelo sobre os dados reais usa `n_init=10`. Como um número menor de reinicializações leva a um ótimo local pior, o custo do nulo é superestimado, sua redução é subestimada, e o ganho sobre o nulo resulta **inflado**.

A verificação direta confirma o efeito, em k=6:

| `n_init` do nulo | Redução no nulo | Ganho sobre o nulo |
|---|---|---|
| 3 (como implementado) | 0,2689 | +0,0397 |
| 10 (simétrico ao real) | 0,2737 | +0,0348 |
| 30 | 0,2815 | +0,0270 |

Com comparação simétrica, o ganho cai 12%; com busca mais exaustiva nos dois lados, cai 32%. **O já reduzido ganho de 0,041 é um limite superior**, e a conclusão de ausência de estrutura sai reforçada. A correção é usar o mesmo `n_init` nos dois lados da comparação.

## 11. Limitações

As limitações do relatório parcial permanecem integralmente válidas e são aqui resumidas.

**Natureza do dado.** Registros policiais medem criminalidade notificada e registrada, não criminalidade ocorrida. Subnotificação diferencial, viés de policiamento e efeito de classificação afastam uma coisa da outra. Toda conclusão deve ser enunciada em termos de registros.

**Variáveis demográficas.** `Vict Descent` e `Vict Sex` descrevem **vítimas**, não autores — o conjunto não contém informação sobre autoria. A distribuição observada reflete a composição demográfica dos territórios combinada com os vieses acima. Agrupamentos organizados por essas variáveis não são perfis criminais; foi justamente para evitar essa leitura que a demografia foi retirada da entrada do modelo nesta etapa.

**Escopo.** Análise restrita a 2020–fevereiro de 2024. Ausência de denominador populacional por divisão policial impede o cálculo de taxas. Coordenadas anonimizadas em nível de quadra limitam a granularidade espacial. Ausência de dados socioeconômicos por território impede controle por variáveis de confusão.

**Amostragem.** Os resultados de agrupamento foram obtidos sobre amostra aleatória de 50.000 registros, e a busca de k sobre subamostra de 15.000. A silhueta é calculada em 4.000 registros por ser de custo quadrático.

---

## 12. Próximos passos

### Prioridade imediata

1. **Elevar `N_INIT` para 50** e produzir a figura de dispersão entre sementes (E6).
2. **Igualar o `n_init` dos dois lados do modelo nulo** e recalcular o ganho (Seção 10.1).
3. **Reportar o V de Cramér demográfico em duas versões**, completa e restrita a vítimas identificadas (E11).
4. **Resolver a pendência de versionamento** da cadeia: decidir entre notebook único ou três arquivos, e alinhar o `LEIA-ME.md` e o repositório (E10).

### Consolidação dos resultados

5. **Estender a busca de k do modus operandi** para `range(2, 31)` e reavaliar (E9).
6. **Adotar critério numérico de pureza** para nomear ou não um cluster (E8).
7. **Refazer a análise de sensibilidade** com múltiplas sementes e `n_init` simétrico, ou removê-la (E7).

### Desenvolvimento da etapa final

8. **Promover a análise de modus operandi a linha principal.** Interpretar os clusters com a tabela oficial de MO codes do LAPD, que o notebook já suporta via arquivo opcional `data/raw/mo_codes.csv`.
9. **Desenvolver o problema supervisionado de classificação do desfecho** (`Status`: prisão *vs.* investigação em curso). A Seção 9.1 mostra que o tipo de crime carrega sinal forte — amplitude de 0,0% a 36,2% na taxa de prisão —, o que torna a tarefa promissora. Desbalanceamento aproximado de 9/91, com avaliação por precisão-revocação em vez de acurácia.
10. **Fechar PP1 com FP-Growth** sobre {`Crm Cd 1, ..., Crm Cd 4`}, reportando suporte, confiança e *lift*.
11. **Construir a página web** prevista como entrega final, organizando os resultados em torno de: a quebra estrutural de 2024, a ausência de estrutura de agrupamento com a evidência que a demonstra, os agrupamentos de modus operandi, e a taxa de prisão por tipo de crime.

---

## 13. Considerações finais

Esta entrega executou o plano de correção do relatório parcial e foi além dele. As cinco falhas previstas foram corrigidas, a circularidade conceitual que comprometia a leitura dos resultados foi eliminada, e o pipeline foi reorganizado em uma cadeia auditável com contratos explícitos entre etapas.

Os instrumentos de validação incorporados responderam formalmente à questão deixada em aberto: não há estrutura de agrupamento nos atributos do fato criminal. O resultado é negativo, mas é um resultado — obtido por procedimento de teste explícito, e não por impressão sobre uma curva.

A esse diagnóstico soma-se o achado de que a partição obtida não é reproduzível entre execuções, o que delimita com precisão o que pode e o que não pode ser afirmado a partir dela.

A execução completa da cadeia acrescentou duas qualificações importantes. A primeira é que a associação demográfica medida é majoritariamente um artefato de quais crimes têm vítima pessoa física registrada — o que torna a resposta a PP2 mais restritiva do que os coeficientes isolados indicariam. A segunda é que existe sinal forte na base, mas em outro lugar: a taxa de prisão varia de 0% a 36% conforme o tipo de crime, amplitude que a partição comprime a um terço.

Em contrapartida, o tratamento de `Mocodes` produziu agrupamentos com silhueta cinco vezes maior e grupos substantivamente coerentes.

A etapa final tem, portanto, três linhas bem definidas: desenvolver a análise de modus operandi como resultado principal; formular a classificação do desfecho, onde o sinal é demonstravelmente forte; e apresentar o K-Modes como o caso documentado em que o método não encontra o que se procurava — acompanhado da evidência que o demonstra.

## Referências


Los Angeles Police Department. *Crime Data from 2020 to Present*. Los Angeles Open Data. Disponível em: https://data.lacity.org/Public-Safety/Crime-Data-from-2020-to-Present/2nrs-mtv8

HUANG, Z. Extensions to the k-Means Algorithm for Clustering Large Data Sets with Categorical Values. *Data Mining and Knowledge Discovery*, v. 2, n. 3, p. 283–304, 1998.

CAO, F.; LIANG, J.; BAI, L. A new initialization method for categorical data clustering. *Expert Systems with Applications*, v. 36, n. 7, p. 10223–10228, 2009.

ROUSSEEUW, P. J. Silhouettes: a graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics*, v. 20, p. 53–65, 1987.

HUBERT, L.; ARABIE, P. Comparing partitions. *Journal of Classification*, v. 2, n. 1, p. 193–218, 1985.

VINH, N. X.; EPPS, J.; BAILEY, J. Information Theoretic Measures for Clusterings Comparison. *Journal of Machine Learning Research*, v. 11, p. 2837–2854, 2010.

BERGSMA, W. A bias-correction for Cramér's V and Tschuprow's T. *Journal of the Korean Statistical Society*, v. 42, n. 3, p. 323–328, 2013.

SATOPÄÄ, V.; ALBRECHT, J.; IRWIN, D.; RAGHAVAN, B. Finding a "Kneedle" in a Haystack: Detecting Knee Points in System Behavior. *31st International Conference on Distributed Computing Systems Workshops*, p. 166–171, 2011.

HAN, J.; PEI, J.; YIN, Y. Mining frequent patterns without candidate generation. *ACM SIGMOD Record*, v. 29, n. 2, p. 1–12, 2000.


---

## Apêndice A — Ambiente e reprodutibilidade

| Item | Especificação |
|---|---|
| Linguagem | Python 3 |
| Bibliotecas | pandas, numpy, scipy, scikit-learn, kmodes 0.12.2, matplotlib, seaborn |
| Semente | 42 |
| Amostra de trabalho | 50.000 registros |
| Subamostra da busca de k | 15.000 registros |
| Subamostra da silhueta | 4.000 registros |

| Item | Especificação |
|---|---|
| Reinicializações (Huang) | 10 |
| Faixa de k testada | 2 a 12 |
| Ambiente | Google Colab |

## Apêndice B — Cadeia de arquivos

| Notebook | Entrada | Saída |
|---|---|---|
| `01_limpeza.ipynb` | `data/raw/Crime_Data_from_2020_to_Present.csv` | `data/processed/lapd_clean.csv` |
| `02_clusterizacao.ipynb` | `lapd_clean.csv` | `amostra_clusters.csv`, `metricas_escolha_k.csv`, `associacao_clusters.csv` |
| `03_visualizacoes.ipynb` | CSVs do notebook 02 | `docs/figuras/*.png` |

Os três devem ser executados na ordem, a partir da mesma pasta de trabalho.

## Apêndice C — Situação consolidada dos erros

| Código | Falha | Origem | Situação |
|---|---|---|---|
| E1 | Amostragem não aleatória | Relatório parcial | Corrigido |
| E2 | Exclusão desbalanceada de registros | Relatório parcial | Corrigido |
| E3 | Cardinalidade desbalanceada | Relatório parcial | Corrigido |
| E4 | Atributos redundantes e quase-constantes | Relatório parcial | Corrigido |

| Código | Falha | Origem | Situação |
|---|---|---|---|
| E5 | Saídas obsoletas no notebook | Relatório parcial | Corrigido |
| E6 | Partição não reproduzível entre execuções | Esta entrega | A corrigir — alta |
| E7 | Sensibilidade indistinguível de ruído | Esta entrega | A corrigir — média |
| E8 | Pureza insuficiente para nomear perfis | Esta entrega | A corrigir — média |
| E9 | Busca de k truncada (modus operandi) | Esta entrega | A corrigir — média |
| E10 | Notebooks sem execução registrada | Esta entrega | **Resolvido**; pendência de versionamento |
| E11 | Associação demográfica inflada por categorias estruturais | Esta entrega | A corrigir — média |